LABORATUVAR7- MOXA1 MAKİNE KENAR BANTLAMA

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad | Grup | Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

*Senaryo: PaketPro'ya YZ'li görsel paket kontrolü **eklenmesi planlanıyor** — proje aşaması değerlendirmesi yapıyorsunuz.*

Kamera → YZ Modeli → OK / RED → Ret mekanizması → Hat hızı

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Kusurlu kenar bantlamaya OK derse; rastgele zamanlı manuel kalite kontrolü (human override) ve mekanik emniyet sensörü ikinci kontrolü yapar.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Kamera verisindeki bozulma/sahtelik "monitoring" (görüntü doğrulama algoritması) ile fark edilir. Şüpheli girdi tespit edildiğinde hat hızı yavaşlatılır, parça RED alanına ayrılır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Güven eşiği %90 altında olursa sistem parçayı RED olarak işaretler veya mekanik duruş (fallback) başlatıp operatör onayına (human override) sunar.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	İkinci aşama manuel kalite kontrolü yapılır ve hat güvenli moda alınır (**Human Override** / **Fail-Safe**).
Girdi manipüle edildi	Görüntü akışı doğrulama sistemiyle izlenir, bozuk girdide parça RED alanına itilir (**Monitoring** / **Fallback**).
Confidence düştü	Güven eşiği %90 altına indiğinde makine otomatik olarak insan müdahalesi ister (**Confidence Threshold** / **Human Override**).

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.